

Asistente Inteligente para Gestión de Consorcios

Optimización de Costos y Matriz de Decisión de IA

Criterio de evaluación - Optimización de costos (20%)

Comparación de modelos, justificación del modelo elegido por tarea, límite de tokens y decisiones de arquitectura orientadas a reducir llamadas innecesarias al LLM.

Objetivo. Minimizar el costo operativo sin degradar la precisión necesaria para clasificar mensajes, extraer datos de reservas y generar palabras clave. La solución utiliza IA solamente donde existe interpretación de lenguaje natural; el resto se resuelve con reglas determinísticas en n8n, Airtable y JavaScript.

Decisión principal

El workflow final realiza **una sola llamada a OpenAI por mensaje**. Esa llamada clasifica la intención y extrae, cuando corresponde, los datos de reserva o palabras clave de consulta. Las validaciones posteriores no consumen tokens.

1. Estrategia de optimización

Durante el desarrollo se eliminó procesamiento redundante. La primera versión contemplaba llamadas adicionales para interpretar reservas y responder consultas. La versión final consolida la interpretación en un único nodo de IA y deriva el procesamiento posterior a componentes determinísticos.

1.1 Arquitectura inicial vs. arquitectura optimizada

Proceso	Enfoque inicial	Enfoque final	Impacto
Clasificación	1 llamada IA	1 llamada IA	Se mantiene.
Reserva SUM	2da llamada IA para extraer fecha/hora	Datos extraídos en la llamada inicial	Se elimina una llamada completa.
Consultas	2da llamada IA con toda la base de conocimientos	Keywords por IA + matching JavaScript/Airtable	Menos tokens y menor latencia.
Disponibilidad SUM	Posible interpretación IA	Airtable + IF + Code	Costo IA = 0.
Solapamiento horario	Posible IA	JavaScript	Resultado reproducible y auditable.
Alertas / mensajes	Podrían redactarse con IA	Plantillas fijas n8n	Costo IA = 0.

Principio aplicado
La IA interpreta lenguaje natural. n8n ejecuta reglas; Airtable almacena memoria; JavaScript realiza matching y validaciones. No se usa un LLM para tareas que pueden resolverse de forma exacta mediante lógica tradicional.

2. Matriz comparativa de modelos

La comparación toma precios estándar publicados por OpenAI para texto. Los importes son por 1 millón de tokens y pueden cambiar con el tiempo; deben verificarse antes de una implementación productiva.

Modelo	Input USD/1M	Output USD/1M	Fortaleza	Uso en este proyecto
GPT-5 nano	\$0.05	\$0.40	Clasificación y extracción simple a muy bajo costo.	Modelo elegido para el clasificador unificado.
GPT-5 mini	\$0.25	\$2.00	Mayor capacidad que nano, costo superior.	No requerido para el MVP.
GPT-5.6 Luna	\$0.20	\$1.20	Modelo económico de propósito general y mayor capacidad.	Alternativa si las pruebas de precisión de

Selección: GPT-5 nano es suficiente para el uso actual porque el modelo no redacta informes extensos ni toma decisiones financieras: clasifica cuatro intenciones, determina criticidad, extrae fecha/hora y genera palabras clave. Las pruebas funcionales del workflow validaron esos usos.

Alternativa: GPT-5.6 Luna se mantiene como opción de escalamiento si en producción aparecieran mensajes ambiguos o una tasa de clasificación insuficiente. Aun siendo más costoso que nano, sigue siendo un modelo de bajo costo frente a alternativas de mayor capacidad.

3. Control de tokens

3.1 Max Output Tokens

El nodo de OpenAI tiene configurado un **Max Output Tokens** limitado. El valor definido actúa como techo de generación, no como consumo fijo: si el JSON requiere menos tokens, solo se consumen los tokens efectivamente generados.

Configuración aplicada

Max Output Tokens: 500. Se dejó margen suficiente para completar el JSON estructurado y evitar respuestas truncadas. Durante las pruebas, un límite más bajo provocó errores, por lo que se ajustó conservando un techo muy inferior a la capacidad máxima del modelo.

3.2 Salida compacta

El prompt exige una respuesta exclusivamente en JSON y prohíbe explicaciones adicionales. La estructura fija reduce variabilidad y evita que el modelo genere texto que no será utilizado por n8n.

```
{
  "intencion": "reclamo | reserva_sum | consulta | fallback",
  "categoria": null,
  "prioridad": null,
  "critico": false,
  "resumen": "",
  "palabras_clave": [],
  "reserva": {
    "fecha": null,
    "hora_inicio": null,
    "hora_fin": null,
    "datos_completos": false,
    "campo_faltante": null
  }
}
```

3.3 Reducción de tokens de entrada

La principal fuente de ahorro no es únicamente el límite de salida. La versión final evita reenviar el mismo mensaje a distintos nodos de IA y evita enviar la Base_Conocimiento completa al modelo en cada consulta. Para las consultas, el modelo entrega palabras clave y el matching posterior se ejecuta localmente.

4. Estimación de costo por volumen

Para cuantificar el impacto se utiliza un escenario ilustrativo de **1.200 tokens de entrada + 150 tokens de salida por interacción**. Es una estimación de planificación, no una medición del workflow. El costo real dependerá del tamaño final del prompt y de cada mensaje recibido.

Modelo	Costo estimado / interacción	1.000 interacciones	5.000	10.000
GPT-5 nano	\$0.000120	\$0.12	\$0.60	\$1.20
GPT-5 mini	\$0.000600	\$0.60	\$3.00	\$6.00
GPT-5.6 Luna	\$0.000420	\$0.42	\$2.10	\$4.20

Bajo este supuesto, GPT-5 nano resulta el modelo más económico. La diferencia aumenta con el volumen de interacciones, por lo que conservar las tareas determinísticas fuera del LLM tiene un impacto directo sobre el costo total.

4.1 Efecto de consolidar llamadas

Si una arquitectura utilizara dos llamadas de IA por interacción para el mismo mensaje -por ejemplo, una para clasificar y otra para extraer la reserva o interpretar la consulta-, el costo variable del modelo podría aproximarse al doble. La versión final evita ese patrón.

Diseño	Llamadas IA por mensaje	Costo relativo
Versión con procesamiento redundante	Hasta 2	≈ 2x en los casos que requieren segunda llamada
Versión final	1	Base de referencia

5. Matriz de decisión por tarea

Tarea	Tecnología	¿Consume tokens?	Justificación
Clasificar intención	GPT-5 nano	Sí	Requiere interpretar lenguaje natural.
Detectar criticidad	GPT-5 nano	Sí, dentro de la misma llamada	Se obtiene junto con la clasificación.
Extraer fecha/hora de reserva	GPT-5 nano	Sí, dentro de la misma llamada	Evita una segunda llamada.
Extraer keywords de consulta	GPT-5 nano	Sí, dentro de la misma llamada	Permite matching posterior sin IA.
Buscar usuario/unidad	Airtable	No	Consulta estructurada.
Buscar conocimiento	Airtable	No	Datos estructurados.
Matching de conocimientos	JavaScript	No	Puntaje por coincidencias.
Validar agenda SUM	Airtable + IF	No	Regla determinística.
Detectar solapamiento	JavaScript	No	Comparación de horarios exacta.
Crear reclamo/reserva	Airtable	No	Persistencia de datos.
Avisos operativos	Slack / Telegram	No IA	Plantillas dinámicas de n8n.
Buscar responsable crítico	Airtable	No	Evita datos hardcodeados.

Conclusión de costos

La arquitectura prioriza una única llamada IA de bajo costo y reutiliza su salida estructurada para todas las rutas. El resto del proceso se ejecuta con componentes determinísticos, reduciendo consumo, latencia y riesgo de respuestas no reproducibles.

6. Alternativas evaluadas y descartadas

6.1 Batch API

OpenAI ofrece procesamiento Batch con descuento para tareas asincrónicas. No se utiliza en este caso porque el asistente requiere respuesta inmediata a mensajes de Telegram. Batch sería apropiado para informes masivos o procesamiento nocturno, no para interacción en tiempo real.

6.2 Modelos de mayor capacidad

No se justifica utilizar modelos de mayor costo para clasificación, extracción de fechas y generación de palabras clave. La lógica crítica del negocio -alta de reservas, validación de disponibilidad y derivación- permanece en n8n y Airtable.

6.3 Segunda llamada para consultas

También se descartó enviar toda la Base_Conocimiento nuevamente al modelo. El clasificador genera palabras clave y un nodo Code puntúa coincidencias. Si no existe un match suficiente, el sistema deriva a un humano en lugar de pagar otra inferencia o permitir que la IA improvise.

7. Síntesis

La estrategia de optimización combina selección de modelo, límite de salida y rediseño del workflow. El ahorro principal proviene de reducir la cantidad de inferencias: una única llamada a GPT-5 nano por mensaje, JSON compacto, Max Output Tokens de 500 y procesamiento posterior mediante Airtable, IF, Switch y JavaScript.

Resultado final

La solución satisface el requisito de integrar un motor de IA con control explícito de tokens y, al mismo tiempo, demuestra una matriz de decisión de costos donde cada tarea se asigna a la tecnología más eficiente.

Precios de referencia: OpenAI API Pricing, consultados el 11/08/2026.